

時間序列資料處理

以海洋熱浪與氣象浮標資料為例

翁其羽




ODB Open API <https://api.odb.ntu.edu.tw/hub>

- 海洋研究船長期蒐集台灣周遭海域之船測資料
 - ODB **CTD** API：溫鹽深儀（CTD）暨附屬探針資料：溫度、鹽度、溶氧、透光度、螢光度 (**39 yrs**, 174.4 million records)
 - ODB **SADCP** API：船載都卜勒流剖儀（SADCP）海流 u、v 流速、流向資料 (1.85 billion records)
- 海洋科學家貢獻之資料集，或整理自其他公開文獻、合作計畫等
 - ODB **ECO** API：海洋生物出現記錄（主要為浮游動物、仔稚魚等）與微塑膠資料集 (172,389 records)
- 轉製海洋科學文獻方法、或由其他全球公開資料庫編譯
 - Marine Heatwaves (**MHW**) API：全球海洋熱浪：**1982-** 迄今月均海表溫及距平值、熱浪級數等 (533.95 million records)
 - **GEBCO** Bathymetry API：全球地形高程資料，15弧秒（約 400 m）解析 (3.748 billion records)
 - Tide API：**TPX09-atlas-v5** 全球潮汐模型 (874.96 million records)
 - WOA23 API：**World Ocean Atlas 2023**：溫度、鹽度、營養鹽、溶氧相關等長期平均資料 (324.26 million records)
 - GLODAP API：**GLODAP v2.2023**（近20種水文化學參數）(1.49M global bottle data from **1,116** cruises, **1972–2021**)
- 工具型 API
 - OGC **WMS/WMTS** Capabilities API：查詢支援開放地理空間協會（OGC）WMS/WMTS 標準之地理圖層資訊

Time-series Lecture Targets


- 找到適當的資料來源：**Open API**、網頁、文獻，並檢視其時空模式（**patterns**）
- 處理時間尺度或精細度不同的時間序列關係
- 初探時間序列分解（**decomposition**）
- 資料來源：
 - 中央氣象署氣象浮標資料（**NODASS**提供）、**ODB** 海洋熱浪**MHW API**
- 附註：
 - 時間有限，科普（如聖嬰、**Ekman transport**）、程式指令細節、套件安裝，請自行 **ask google or AI**

Oceanic Niño Index (ONI)




The Oceanic Niño Index (ONI): running 3-month mean SST anomaly for the Niño 3.4 region (5°N-5°S, 120°-170°W)


El Niño/La Niña event: 5 consecutive overlapping 3-month periods $>/< \pm 0.5^{\circ}\text{C}$




Oceanic Niño Index (ONI), El Niño and La Niña




(a) SST Anomalies in DJF 1997/1998



(b) SST Anomalies in DJF 1973/1974





www.cwa.gov.tw/V8/C/C/Knowledge/knowledge_4-1.html



<https://rsiasacademy.com/el-nino-upsc/>

Oceanic Niño Index (ONI) time-series



<https://climate.cwa.gov.tw/ENSO?subpage=Intro>



Result: 利用 ODB MHW API 檢視 Niño3.4 SST Anomaly pattern

Open API of Marine Heatwaves 1.0.0 OAS 3.1

https://api.odb.ntu.edu.tw/search/schema?node=odb_mhw_v1&num=1

Marine heatwaves (MHWs) evaluated from 0.25-degree gridded NOAA OISST v2.1, compiled by ODB, Taiwan. Reference: Jacox, Alexander, Bograd, and Scott (2020), Thermal Displacement by Marine Heatwaves, Nature, 584, 82–86, doi:10.1038/s41586-020-2534-z

Provider: Ocean Data Bank (ODB), Taiwan. Data: <https://www.noaa.gov/products/optimum-interpolation-sst> (NOAA OISST v2.1)
Last updated: 2025-04-14

Servers
<https://eco.odb.ntu.edu.tw>

Marine Heatwave

GET /api/mhw Query MHW data as JSON

Query MHW data by longitude/latitude/date (in JSON), providing monthly marine heatwave levels, sea surface temperature (SST), SST anomalies, and thermal displacements at a 0.25° x 0.25° global resolution. See more: <https://eco.odb.ntu.edu.tw/pub/MHW>


- One-point MHWs without time-span limitation. e.g. /api/mhw?lon0=135&lat0=15
- Bounding-box < 10 x 10 in degrees. 10-years time-span limitation. e.g. /api/mhw?lon0=135&lon1=140&lat0=15&lat1=30&start=2013-01-01 (data from 2013/01/01 to 2022/12/01)
- Bounding-box > 10 x 10 in degrees. 1-year time-span limitation. e.g. /api/mhw?lon0=135&lon1=150&lat0=15&lat1=30&start=2013-01-01 (data from 2013/01/01 to 2013/12/01)
- Bounding-box > 90 x 90 in degrees. 1-month time-span limitation. e.g. /api/mhw?lon0=180&lon1=180&lat0=90&lat1=90&start=2013-01-01 (data of 2013/01/01)

Parameters


Name	Description
lon0 ^{required}	Minimum longitude, range: [-180, 180]
number (query)	lon0
lat0 ^{required}	Minimum latitude, range: [-90, 90]
number	lat0

[Try it out](#)


https://api.odb.ntu.edu.tw/hub/swagger?node=odb_mhw_v1






<https://psl.noaa.gov/data/timeseries/month/data/nino34.long.anom.data>



El Niño and Disease Outbreaks



From Fig.4. Anyamba, A., Chretien, JP, Britch, S.C. *et al.*
Global Disease Outbreaks Associated with the 2015–2016 El Niño Event.
Sci Rep **9**, 1930 (2019). <https://doi.org/10.1038/s41598-018-38034-z>



- 時間序列轉化為適當的**事件資料**，常有助於統計分析，尤其面對非線性、不同時間規模或精細度的資料。
- 事件發生的**頻繁**與否、如何**分類**都可以著力，但須合理
- 有相關性或顯著差別，並不能推演為具有**因果性** (causality)

2025/07/17

Time-series Decomposition by STL

```
# 1. Simulate trend + seasonality + noise
np.random.seed(2024)
n = 100
t = np.arange(1, n+1)
time_index = pd.date_range("2000-01-01", periods=n, freq="ME")

mu = -5 + 0.1 * t           # 線性趨勢
ss = np.sin(2 * np.pi * t / 12) # 每 12 期的季節性
e = 0.5 * np.random.randn(n)   # 隨機噪音
y = mu + ss + e


df = pd.DataFrame({"y": y, "signal": mu + ss}, index=time_index)
```

```
from statsmodels.tsa.seasonal import STL
```


```
stl = STL(df["y"],
           period=12,
           robust=True).fit()
fig = stl.plot()
```

- **STL**: Seasonal and Trend decomposition using LOESS
- 為何須了解時間序列中的趨勢、季節性與殘差 (**residuals**) ?
- **STL** 有何限制 ?

Time-series with Trend and Seasonality



Seasonal Decomposition of SST





Time-series Decomposition by EEMD (進階參考)

```
# 1. Simulate trend + seasonality + noise
np.random.seed(41)
n = 600
t = np.arange(n)
time_index = pd.date_range("1970-01-01", periods=n, freq="ME")
random_ph1 = np.random.uniform(0, np.pi)
random_ph2 = np.random.uniform(0, np.pi)


mu = -2 + 0.001 * t          # 線性趨勢 -2 + 600 * 0.001 = -1.4
ss = 0.8 * np.sin(2 * np.pi * t / 12) # 每 12 期的季節性
mm = 0.23 * np.cos(2 * np.pi * t / 43 + random_ph1) # mid-term seasonality
ll = 0.15 * np.sin(2 * np.pi * t / 101 + random_ph2) # long-term seasonality
e = 0.5 * np.random.randn(n) # 隨機噪音
y = mu + ss + mm + ll + e

df = pd.DataFrame({"y": y, "signal": mu + ss + mm + ll}, index=time_index)
```

Seasonal Decomposition of test example



Long-term testing trend from EEMD + LOWESS



EEMD: Ensemble empirical mode decomposition (EMD)


- EMD這種分解技術，不依賴於穩態假設，將訊號分解為具有不同振盪模式的基函數
- 傳統傅立葉 (FFT) 告訴你有那些固定頻率存在，就好像把原始訊號拆解成一個個固定但不同頻率的正弦波組成。但從左例可以看到：真實世界的振盪很少是純正弦波，而是調幅調頻的複合式振盪 + 隨機變數。
- **IMF (Intrinsic Mode Function)** 代表一個特徵時間尺度 (模態) 的振盪成分
- 迭代尋找每個IMF：連接訊號的極大、極小值形成上下包絡線 (envelope)，移除包絡線平均後，檢查是否符合IMF條件。
- **IMF條件**：極值點數量與過零點數量相等或至多差一，且上下包絡線的平均趨近零
- 若符合，得到IMF₁，繼續迭代找下一個IMF。IMF₁：最快的振盪、IMF₂：次快...
- 為什麼？
 - 原始訊號 = 快振盪 + 慢變化的基線
 - 移除包絡平均 = 移除慢變化基線
 - 結果 = 在該時間尺度上的"純"振盪
- 剩下來的殘差，仍具有長期趨勢成份 (含單調趨勢)
- **EEMD改進**：每次拆解IMF，加入白噪音後找尋上下包落線平均，解決EMD的模態混合問題，使每個IMF更純淨地代表單一時間尺度。

Colab程式碼

https://colab.research.google.com/github/ODBapp/2025_NODASS_workshop/blob/main/src/timeseries/EEMD01.ipynb



氣象浮標資料處理



- 氣象浮標為連續觀測之時間序列資料，處理上需注意缺值、離群值與在時間尺度上的處理。從不同的資料變數月平均可知具有明顯的季節性耦合，尤其是複合性的週期訊號，在處理相關性分析也須留意。
- 和更長時間規模的 **Niño3.4 SST** 距平值相比，顯示氣象浮標事件 **SST** 距平值受季風因素影響有顯著的季節性週期，和 **Niño3.4 SST** 距平值差異甚大。
- 進階參考範例中使用 **EEMD** 處理示性波高（**Significant wave height**）趨勢、週期性可和 **STL** 結果比較。
- 以下將使用文獻中利用風速、風向等資料計算湧升流的湧升指數（**Upwelling Index, UI**）為例

氣象浮標資料：由風速、風向計算湧升指數

The daily composited wind data were first calculated from the 6-hourly data. The daily UI (in $\text{m}^2 \text{s}^{-1}$) was then calculated using the following equations:

$$\text{UI} = \frac{\tau}{f \rho_w} \cos(\alpha - \beta) \quad (1)$$


$$\tau = \rho_a C_d V^2 \quad (2)$$

$$f = 2 \omega \sin(\varphi) \quad (3)$$

$$C_d = (0.8 + 0.065 V) \times 0.001 \quad (4)$$

where τ is the wind stress, ρ_a is the air density (1.22 kg m^{-3}), ρ_w is the seawater density (1026 kg m^{-3}), C_d is the drag coefficient calculated using the empirical equation of [22], f is the Coriolis parameter (s^{-1}), α is the wind direction, β is the general shoreline orientation, ω is the rotation rate of the Earth ($7.2921 \times 10^{-5} \text{ rads}^{-1}$), φ is the latitude, and V is the wind speed (in m s^{-1}).

- 計算風應力 τ ，並考慮柯氏力所造成 **Ekman** 作用而形成離岸流，帶動湧升流；意謂 **Ekman** 作用把表水推離岸 → 較冷的深層水上湧。計算所得之湧升指數 (**Upwelling Index, UI**) 正值代表湧升



by Paul Webb





```
RHO_AIR = 1.22      # air density in kg m-3
RHO_W   = 1026.0    # seawater density in kg m-3
def drag_coef(V):    # drag coefficient 阻力係數的經驗公式
    return (0.8 + 0.065 * V) * 1e-3  # Huang et al. 2021

def calc_ui(df: pd.DataFrame, site_name: str, coast_angle: float) -> pd.Series:
    """
    由浮標 dataframe 產生月平均 Upwelling Index (UI)，需手動指定 site 與岸線角度。
    Parameters
    -----
    df : DataFrame
        需含欄位 'Wind'(m/s)、'Win_Dir'(deg, dir-from)
    site_name : str
        浮標所屬站點名稱，會自動帶入 CWB_SITES 對應的緯度
    coast_angle : float
        岸線走向角度 (deg, 順時針自真北，例：文獻中台灣東部海域北段≈18°)
    Returns
    -----
    Series (DatetimeIndex, 月頻率)：upwelling index 單位為 m²/s
    """
    lat = CWA_SITES[site_name][0]
    V = df["Wind"]
    α = (df["Wind_Dir"] + 180.) % 360  # 風向→風去向

    # cos(α-β) is the projection vector of τ: wind stress
    cos_ab = np.cos(np.deg2rad(α - coast_angle))
    Cd = drag_coef(V)
    tau = (RHO_AIR * Cd * V**2) * cos_ab  # τ: wind stress · cos(α-β)

    f = 2 * 7.2921e-5 * np.sin(np.deg2rad(lat)) # Coriolis parameter (s-1)
    ui = tau / (RHO_W * f)  # m² s⁻¹ (與論文一致)
    return ui
```


氣象浮標資料 → 逐日湧升指數




- 湧升流為較冷的深層水上湧，則湧升指數與**SST**的關係會是？如何分析？


From [Huang et. al., 2021 Fig.3](#)

逐日湧升指數 vs SST Anomalies


Upwelling and SST Anomalies Overlay



STL Residuals and Lagged SST Anomalies Overlay



Cross-correlation of Residuals
(Max $r = -0.38$ at lag -1)



- 湧升指數 **UI** (以**STL**移除趨勢、季節性) 領先 **SST** 距平值 **+1 lag** 顯著負相關。
- 為何 **UI** 用 **STL**，但 **SST** 距平值不以此處理？
- 但其實並不是每一段逐日**UI** 都和 **SST** 距平值有這麼顯著關係，**SST** 仍受其他許多外在因素影響。

Take Home Messages

- 開源函式庫 + **AI + Vibe coding** 已經使資料處理技術不再是最大門檻
 - 了解資料的本質與如何應用，才能驅動 **AI** 幫忙做出有用的事
 - 做為入門的第一步：找到適合的科學文獻參考，幫助頗大！

- 初探時間序列：

- 時間序列的相關性、因果關係，往往存在錯誤陷阱與迷思
 - 時間拉長，真實世界的時間訊號往往都具非線性、複雜因子，所謂的相關性往往不復存在
- 將連續的時間序列，轉換成指數、事件，常有助於對影響因子的統計分析

